

Práctica Nro.5

Parte 1 - Datos Abiertos

Ejercicio 1

Investigar y mencionar 3 sitios de datos abiertos donde se puedan obtener datasets relevantes para diferentes análisis a realizar. Describa el tipo de datos que se puede encontrar en cada uno.

- datos.gob.ar
 - Es el portal nacional de datos abiertos de Argentina, que centraliza y publica datos generados por los organismos de la Administración Pública Nacional. Su objetivo es promover la transparencia, la participación ciudadana y la innovación.
 - **Tipos de datos que se pueden encontrar:**
 - Datos económicos y financieros (ej: precios, producción, comercio).
 - Datos sociales (ej: educación, salud, empleo).
 - Datos ambientales (ej: calidad del aire, recursos naturales).
 - Datos de gobierno abierto (ej: estructuras orgánicas, licitaciones).
 - Datos geoespaciales y territoriales.
- data.europa.eu
 - Portal oficial de datos abiertos de la Unión Europea, que recopila datasets de instituciones europeas, estados miembros y otros organismos públicos. Está basado en el estándar de metadatos DCAT-AP para garantizar interoperabilidad.
 - **Tipo de datos que se pueden encontrar:**
 - Datos estadísticos europeos (economía, población, comercio).
 - Datos sobre políticas públicas y legislación.
 - Datos de movilidad, transporte y medio ambiente.
 - Datos de investigación e innovación.
 - Datos geoespaciales (ej: uso del suelo, cartografía).
- data.gov
 - Es el portal de datos abiertos del gobierno de los Estados Unidos, que proporciona acceso a datos federales, estatales y locales. Su creación fue impulsada por la Open Government Directive de 2009.
 - **Tipo de datos que se pueden encontrar:**
 - Datos demográficos y censales.
 - Datos de salud y seguridad pública.
 - Datos climáticos y ambientales (ej: NOAA, NASA).
 - Datos económicos y laborales (ej: empleo, comercio).
 - Datos educativos y de investigación.

Ejercicio 2

¿Cuál es la diferencia entre datos públicos y datos abiertos? Proporciona un ejemplo de cada tipo.

Los **datos públicos** son "cualquier dato generado en el ámbito gubernamental, o que se encuentra bajo su guarda". **Características clave:**

- Son datos que pertenecen o son custodiados por el gobierno
- Pueden estar disponibles para consulta pero con restricciones
- No necesariamente son fácilmente reutilizables

Ejemplo: Un PDF escaneado de un informe anual de gestión gubernamental que está disponible en el sitio web de un ministerio. Aunque es público, está en formato no procesable automáticamente.

Los **datos abiertos** son "aquellos de origen público o no a los que cualquier persona puede acceder, usar y compartir libremente. Solo deben atribuirse y compartirse con la misma licencia con la que fueron publicados". **Características clave:**

- Completos y primarios (recolectados en la fuente)
- Oportunos y accesibles
- Procesables por máquinas
- No discriminatorios
- No propietarios
- Con licencia de uso libre

Ejemplo: Un archivo CSV descargable desde datos.gob.ar por ejemplo, con los precios de productos básicos en diferentes comercios, publicado con licencia Creative Commons Atribución 4.0, que permite su reutilización, análisis y creación de aplicaciones.

Ejercicio 3

Mencione 3 tipos de licencias que pueden tener los datos abiertos, describiendo diferencias entre ellas.

1. Open Data Commons Public Domain Dedication and License (PDDL)

1. Esta licencia "permite difundir, reutilizar o adaptar los datos sin restricción alguna".

Características principales:

1. Dedicación al dominio público
2. Sin requisitos de atribución
3. Sin restricciones sobre obras derivadas
4. Máxima libertad de uso, incluso comercial

2. Open Data Commons Attribution License

1. Esta licencia exige la referencia a la autoría o fuente de los datos para la reutilización de la información. **Características principales:**

1. Requiere atribución al autor original
2. Permite uso comercial
3. Permite creación de obras derivadas
4. No exige compartir igual

3. Open Data Commons Open Database License (ODbL)

1. Esta licencia permite la reutilización de los datos siempre que se reconozca la autoría de la información original y se mantenga la misma licencia en las obras derivadas. *Características principales:*
 1. Requiere atribución
 2. Exige "compartir igual" (share-alike)
 3. Las obras derivadas deben mantener la misma licencia
 4. Permite uso comercial

Ejercicio 4

Suponga que tiene acceso a un dataset abierto sobre los niveles de contaminación del aire en diferentes ciudades del país. ¿Qué tipos de análisis podría realizar para obtener información útil?

Para obtener información útil podríamos realizar los siguientes análisis:

- **Análisis Temporal y de Tendencia** para identificar patrones a lo largo del tiempo.
- **Análisis Comparativo y Ranking** para evaluar el desempeño relativo entre ciudades.
- **Análisis Geográfico y Espacial** para identificar patrones a nivel territorial.
- **Análisis de Correlación y Factores Asociados** para identificar relaciones con otras variables.
- **Análisis de Impacto en Salud Pública** para evaluar consecuencias en la población.
- **Análisis Predictivo y Modelado** para prever escenarios futuros.

Ejercicio 5

¿Cuáles son las condiciones de la licencia creative commons?

Las licencias **Creative Commons** se construyen combinando cuatro condiciones principales:

1. **Atribución (BY)**: Reconocer la autoría original de la obra
2. **No Comercial (NC)**: Prohíbe el uso comercial de la obra
3. **Sin Obras Derivadas (ND)**: No permite modificar la obra original ni crear derivados
4. **Compartir Igual (SA)**: Las obras derivadas deben mantener la misma licencia

Ejercicio 6

¿Qué significa tener datos IA-ready?

Los **datos IA-ready** son aquellos que "cumplen una serie de requisitos técnicos, estructurales y de calidad que optimizan su aprovechamiento por parte de los algoritmos de inteligencia artificial". **Características Principales:**

- 1. *Calidad y Completitud*
 - 1. Ausencia de errores e inconsistencias
 - 2. Datos completos sin valores faltantes críticos
 - 3. Estructuras homogéneas que facilitan el procesamiento automático
- 2. *Formato y Estructura Adecuados*
 - 1. Formatos legibles por máquinas (CSV, JSON, XML en lugar de PDF o imágenes)
 - 2. Metadatos ricos y estandarizados
 - 3. Estructuras consistentes across diferentes conjuntos de datos
- 3. *Contexto y Documentación*
 - 1. Documentación completa del origen de los datos
 - 2. Contexto suficiente para alinear los datos con el uso que la IA les dará
 - 3. Etiquetado exhaustivo y descriptivo

Ejercicio 7

¿Cuáles son los principios FAIR-R y sus requisitos?

Principio	Descripción	Importancia para IA
Findable (Encontrables)	Datos fácilmente localizables	Permite a los modelos encontrar datos relevantes
Accessible (Accesibles)	Disponibles sin barreras	Elimina obstáculos para el entrenamiento
Interoperable (Interoperables)	Compatibles entre sistemas	Facilita la combinación de múltiples fuentes
Reusable (Reutilizables)	Preparados para múltiples usos	Maximiza el valor de los datos
Readiness (Preparados para IA)	Optimizados específicamente para IA	Garantiza eficiencia en el entrenamiento

Requisitos Específicos para IA

- *Evitar Sesgos*
 - Cobertura suficiente que evite sesgos en los modelos
 - Datos representativos de la diversidad real
 - Equilibrio en las categorías y clases
- *Aspectos Legales y Éticos*
 - Licencias claras que regulen el uso en IA

- Consideraciones éticas sobre el uso de los datos
 - Cumplimiento con regulaciones de privacidad
 - *Volumen y Escalabilidad*
 - Suficiente volumen para entrenamiento efectivo
 - Capacidad de crecimiento con el tiempo
 - Estructura que permita procesamiento distribuido
-

Parte 2 - Visualización de Datos

Ejercicio 1

Explique que es una medida y una dimensión

Dimensión: Las dimensiones son "datos cualitativos, como un nombre o una fecha".

Características:

- Datos cualitativos o categóricos
- Contienen información descriptiva
- Suelen ser campos de texto o fechas
- Definen el nivel de granularidad de la vista

Medida: Las medidas son "datos numéricos cuantitativos". *Características:*

- Datos numéricos cuantificables
- Pueden ser agregados (sumados, promediados, etc.)
- Representan métricas o KPIs
- Se calculan en función de dimensiones

Ejercicio 2

Explique la diferencia entre un dato discreto y un dato continuo

Dato Discreto: Los campos discretos contienen un número finito de valores. *Características:*

- Valores finitos y contables
- No permiten valores intermedios
- Representan categorías o grupos distintos
- Se pueden enumerar completamente

Dato Continuo: Los campos continuos pueden contener un número infinito de valores.

Características:

- Valores infinitos dentro de un rango
- Permiten valores intermedios y decimales

- Representan mediciones o cantidades
- Forman un espectro o rango continuo

Ejercicio 3

¿Por qué es importante preparar los datos?

La **preparación de datos** es fundamental porque "los datos crudos rara vez están listos para su análisis inmediato". *Razones principales:*

1. Calidad y Confiabilidad

1. Eliminar errores e inconsistencias que distorsionan los análisis
2. Garantizar que los datos sean precisos y representativos de la realidad
3. Evitar conclusiones erróneas basadas en datos corruptos

2. Compatibilidad con Herramientas de Análisis

1. Formatear datos para que sean procesables por herramientas como Tableau, Power BI
2. Estructurar datos en formatos legibles por máquinas (CSV, JSON vs PDF escaneados)
3. Permitir la automatización del análisis

3. Eficiencia en el Procesamiento

1. Reducir tiempo de análisis al tener datos bien organizados
2. Minimizar reprocesos y recálculos
3. Optimizar el rendimiento de las herramientas de visualización

Ejercicio 4

Dadas las situaciones que se presentan a continuación, decidir qué tipo de gráfico utilizaría para visualizar la información de manera clara y efectiva. Justifique su elección indicando por qué ese tipo de gráfico es el más adecuado para cada caso.

1. Comparación de suscripciones anuales por región geográfica: Se cuenta con un conjunto de datos de las suscripciones anuales de una empresa de telefonía celular en distintas regiones (Norte, Sur, Este, Oeste) durante los últimos 5 años. ¿Qué tipo de gráfico utilizaría para comparar las ventas entre las regiones durante los 5 años?

Mi elección sería el **Gráfico de Barras**. Justificación:

- *Naturaleza de los datos*
 1. Dimensión categórica: Regiones geográficas (Norte, Sur, Este, Oeste) → Discreta
 2. Dimensión temporal: 5 años → Discreta
 3. Medida: Cantidad de suscripciones → Continua
- Los gráficos de barras o columna nos permiten comparar valores numéricos como números enteros y porcentajes, nos dejan ver variaciones en categorías o subcategorías escalando el ancho o alto a través de barras o rectángulos simples y espaciados.

2. Análisis de la distribución de las edades de clientes: Se tiene un dataset con datos de los clientes de una tienda virtual, entre ellos, la edad. El objetivo es entender cómo se distribuyen las edades de los clientes. ¿Qué tipo de gráfico utilizará para representar la distribución de las edades de los clientes?

Está medio rara la pregunta, entiendo que quieren la distribución por edad

Mi elección sería el **Gráfico de Barras**. Justificación:

- En el eje X tenemos los rangos de edad.
- En el eje Y tenemos la cantidad de clientes en cada rango.

3. Relación entre el precio y la puntuación otorgada por el cliente: Se tiene información sobre el precio de diferentes servicios ofrecidos y la calificación otorgada por los clientes. ¿Qué tipo de gráfico usaría para analizar si existe una relación entre el precio del producto y la puntuación marcada por el cliente?

Mi elección sería el **Gráfico de Dispersión**. Justificación:

- "Son útiles para mostrar la correlación entre 2 variables"
- La variable X sería el precio del servicio → Continua.
- La variable Y sería la puntuación del cliente → Continua.

4. Análisis de los préstamos de libros por género: Se cuenta con el registro de los préstamos de una biblioteca escolar. Entre los datos de cada uno de estos se tiene el género del libro (narrativa, poesía, cuento, novela y biografía). ¿Qué gráfico es adecuado para visualizar la proporción de préstamos de cada género?

Mi elección sería el **Gráfico de Torta**. Justificación:

- "Es una visualización común [...] que se utiliza para mostrar cómo unas pocas variables se comparan en porcentaje entre ellas y con el total"
- Exactamente 5 categorías (narrativa, poesía, cuento, novela, biografía) → dentro del rango ideal.
- Probablemente se cumpla que un género predomine sobre el resto.

5. Se han almacenado datos de registro de la temperatura promedio del mar, a partir de mediciones diarias frente a la costa de Las Toninas, un kilómetro mar adentro. Esta medición se viene realizando durante los últimos 7 años para estudios del comportamiento de la fauna del lugar.

Dado el siguiente esquema de la base de datos:

TipoGradoTemp (**#tipoGradoTemp**, descripcionTipoGrado)

TemperaturaRegistrada (**#registroTemp**, fecha, hora, valorTemp, #tipoGradoTemp)

TemperaturasPromedio (**#registroProm**, fecha, valorProm)

1. ¿Qué tipo de gráfico utilizará para mostrar los cambios de la temperatura promedio a lo largo del tiempo?

Mi elección sería el **Gráfico de Líneas**. Justificación:

- "Un gráfico de línea muestra las relaciones de los cambios en los datos en un período de tiempo, facilitando la identificación de tendencias"
- Período de 7 años → Serie temporal perfecta para gráfico de líneas
- Temperatura promedio → Variable continua ideal para este gráfico
- Identificación de patrones estacionales → Fortaleza del gráfico de líneas

2. ¿Cuáles tablas son relevantes para presentar el análisis?

Tablas relevantes:

- **TemperaturasPromedio:** Los campos esenciales de esta tabla son `fecha` y `valorProm` ya que son los valores promedios a visualizar y la fecha específica que es necesaria para el gráfico de líneas.
- **TemperaturaRegistrada:** Me parece relevante que esta tabla posea `#tipoGradoTemp`, esto nos permitiría distinguir las mediciones por tipo de grado en diferentes líneas ya que aunque usemos el valor promedio, los diferentes tipos pueden tener escalas diferentes que hagan que el gráfico muestre información confusa o incorrecta.

Además, el dataset muestra la cantidad de especies que se identificaron en el mar en las 5 distintas categorías (Moluscos, Artrópodos, Cnidarios, Peces y Mamíferos marinos).

6. Dado el siguiente esquema de la base de datos:

CategoriaEspecie (`#cat_especie`, `cat_nombre`)

EspecieIdentificada (`#especie`, `#cat_especie`, `nombre_especie`, `cantidad`)

3. ¿Qué gráfico utilizaría si se quiere visualizar la proporción de especies de cada categoría?

Mi elección sería el **Gráfico de Torta**. Justificación:

- "Es una visualización común [...] que se utiliza para mostrar cómo unas pocas variables se comparan en porcentaje entre ellas y con el total"
- Exactamente 5 categorías (Moluscos, Artrópodos, Cnidarios, Peces, Mamíferos marinos) → dentro del rango ideal de 2-5 variables
- Probablemente se cumpla que una categoría de especie predomine sobre el resto.

4. De todas las tablas propuestas, indicar cuál o cuáles son relevantes para presentar el análisis

Las **Tablas relevantes** en este caso son ambas tablas, necesitamos ambas ya que la primera es la que tiene `cat_especie` para la relación y `cat_nombre` para mostrar los nombres de

las categorías, y la segunda es la que tiene `cat_especie` para agrupar por categoría y `cantidad` para calcular las proporciones.

Más ejercicios...

7. Visualización de las estadísticas de una cadena de supermercados

Una cadena de supermercados quiere contar con estadísticas de las ventas por sucursal y por tipo de producto a lo largo del último año (mes a mes). Se quiere identificar las sucursales con mayores ventas y los tipos de productos que generan más ingresos.

Esta cadena de supermercados quiere visualizar:

- La cantidad de productos vendidos de cada categoría para todas las sucursales, para conocer qué tipo de producto es el que más se vende.
- El total ingresos de la sucursal número 10, mes a mes, durante los últimos 12 meses, para determinar si hubo o no un incremento de los ingresos.

Para ello dispone de una base de datos con el siguiente esquema:

Venta (id_venta, fecha_venta, id_sucursal, monto_total)

Item_Venta (id_venta, id_producto, cant)

Sucursal (id_sucursal, ubicación, cant_empleados)

Producto (id_producto, nombre_producto, desc_producto, precio_unit, categoria)

Cliente (id_cliente, nombre_cliente, apellido_cliente, tipo_cliente)

Determine qué tipo de gráfico podría utilizar y justifique su elección.

Con los esquemas proporcionados, elegir cuáles -con sus atributos- son relevantes para presentar el análisis visual propuesto anteriormente

Para el primer gráfico que corresponde a la **cantidad de productos vendidos de cada categoría para todas las sucursales** mi elección es un **Gráfico de Barras**. Justificación:

- "Los gráficos de barras o columna nos permiten comparar valores numéricos como números enteros y porcentajes"
- "Usan la longitud de cada barra para representar el valor de cada variable"
- Ideal para comparar categorías y identificar rápidamente cuál tiene mayor volumen
- En el eje X tendríamos las categorías.
- En el eje Y las cantidades vendidas.

Para el segundo gráfico que corresponde a **el total ingresos de la sucursal número 10, mes a mes, durante los últimos 12 meses** mi elección es un **Gráfico de Líneas**. Justificación:

- "Un gráfico de línea muestra las relaciones de los cambios en los datos en un período de tiempo, facilitando la identificación de tendencias"
- Perfecto para mostrar evolución mensual y detectar incrementos/decrementos

Las **Tablas Relevantes** para el primer gráfico son:

- **Item_Venta**: Posee el `id_producto` para agrupar por producto y `cant` para contabilizar.
- **Producto**: Posee el `id_producto` para generar una relación con Item_Venta y `categoria` para mostrar la categoría del producto en el gráfico.

Las **Tablas Relevantes** para el segundo gráfico son:

- **Venta**: De esta tabla podemos obtener el `id_sucursal` de la sucursal 10, con `monto_total` ir contabilizando los montos de las ventas generadas, y con `fecha_venta` podemos ir agrupando las ventas de a meses.

Parte 3 - Graficando con Tableau

En esta sección, utilizarás [Tableau Public](#) para explorar y visualizar un datasets sobre el uso de dispositivos móviles y comportamiento del usuario. El archivo con dicho dataset estará adjunto a esta práctica, y tu objetivo será importar este en Tableau y generar gráficos que representen patrones y relaciones claves en los datos.

Importante: Agrega leyendas, etiquetas, títulos y otros elementos visuales a cada gráfico, según crea necesario, asegurándose de esta manera que los gráficos sean comprensibles y que proporcionen contexto suficiente.

1. Mobile Device Usage and User Behavior Dataset

Este dataset contiene una muestra de 700 usuarios y detalla patrones de uso de dispositivos móviles. Incluye métricas como el tiempo de uso de aplicaciones, consumo de batería y de datos móviles. Cada usuario está clasificado en una de cinco categorías de comportamiento, desde uso ligero hasta extremo. A continuación se describen las columnas más relevantes del dataset:

- User ID: Identificador único del usuario.
- Device Model: Modelo del dispositivo utilizado.
- Operating System: Sistema operativo del dispositivo (iOS o Android).
- App Usage Time: Tiempo diario en minutos dedicado a aplicaciones.
- Screen On Time: Promedio diario de tiempo de pantalla activa.
- Battery Drain: Consumo diario de batería en mAh.
- Number of Apps Installed: Total de aplicaciones instaladas en el dispositivo.
- Data Usage: Consumo diario de datos en MB.
- Age: Edad del usuario.
- Gender: Género del usuario (Masculino o Femenino).
- User Behavior Class: Clasificación de comportamiento en una escala de 1 a 5, según los patrones de uso.

Ejercicios:

1. Crea un gráfico de barras horizontales que muestre la cantidad de usuarios para cada modelo de dispositivo. Segmenta las barras por el color del sistema operativo (iOS y Android) para identificar las preferencias de uso por sistema.
2. Muestra una línea que refleje el promedio de aplicaciones instaladas y otra línea para el promedio de datos consumidos, ambos valores en función de la edad del usuario.
3. Crea un histograma que muestre la distribución del número total de aplicaciones instaladas en dispositivos con sistema operativo iOS (filtra los datos para que solo se incluyan dispositivos iOS)
4. Representa en un gráfico de líneas la relación entre la batería gastada y los datos consumidos. Este gráfico permitirá observar cómo el consumo de datos puede influir en el uso de batería.

I'm not doing this.